Exploración del corpus personal con Voyant Tools

Lectura distante del corpus literario de Umbral Weird

Eugenio Torres Flawiá

1. Corpus y muestra

Retomando la devolución del Trabajo Práctico del primer cuatrimestre, esta actividad invierte las jerarquías del anteproyecto: la muestra ya no es la infraestructura técnica sino el corpus crítico-literario de Umbral Weird. Se seleccionaron cinco textos narrativos de tres autores centrales de la investigación, convertidos a texto plano UTF-8:

Texto	Autor/a	Tokens (Voyant)	Estado material
Territorios sin cartografiar	Kike Ferrari	30.566	OCR con daño sistemático, reparado parcialmente
El conserje y la eternidad	Ricardo Romero	35.021	OCR de buena calidad, paratexto recortado
La habitación del presidente	Ricardo Romero	12.121	OCR de buena calidad, paratexto recortado
El patio del vecino	Mariana Enríquez	7.123	Nacido digital (.txt original; se descartó la extracción del PDF por pérdida de ligaduras)
La casa de Adela	Mariana Enríquez	4.157	Nacido digital (versión web) — reemplaza a un OCR dañado

El corpus completo suma 88.988 palabras y 11.719 formas únicas según el Sumario de Voyant. La muestra combina deliberadamente dos novelas breves, un libro de relatos y dos cuentos, de modo que la exploración permita observar tanto tendencias transversales del corpus como firmas léxicas propias de cada texto y autor.

2. Curaduría previa: la materialidad del corpus

La primera constatación de la actividad ocurrió antes de abrir Voyant. Los cinco archivos presentaban tres estratos materiales distintos: un texto nacido digital (El patio del vecino), dos digitalizaciones de buena calidad con paratexto editorial completo (las novelas de Romero, que arrastraban biografía de solapa, colofón, ISBN, citas de prensa y catálogo editorial), y dos digitalizaciones dañadas: Territorios sin cartografiar estaba codificado en Mac Roman (no UTF-8), con finales de línea de Mac clásico, cortes silábicos convertidos en puntos intraléxicos y una pérdida sistemática de glifos que truncaba toda la familia de sustantivos en -ción (ficci por

ficción, habitaci por habitación); La casa de Adela presentaba un daño de OCR severo, a nivel de carácter, que no admitía reparación automática confiable.

Sobre esa base se aplicó una curaduría documentada: conversión de encoding, recorte de paratextos (índices, prólogo ajeno, colofones, contratapas y encabezados web), reunión de palabras cortadas por guion blando (773 casos en total), reparación de 143 truncamientos de -ción mediante regla explícita, y eliminación de folios. La decisión más drástica fue el reemplazo de fuente: la versión OCR de La casa de Adela resultó irreparable y se la sustituyó por una versión nacida digital del mismo cuento. En el caso de El patio del vecino, la curaduría dejó una lección adicional: la extracción de texto desde el PDF, que parecía la fuente superior, perdía sistemáticamente las ligaduras fi (modi caciones, con anza, edi cios) porque una de sus fuentes tipográficas carece de mapa Unicode completo, y hubo que restaurar la versión .txt nacida digital original, que estaba intacta. La calidad de una fuente no es un atributo del formato sino del pipeline completo de extracción. El daño no reparable dejó además una huella medible: en la tabla de Términos del documento de Territorios sobreviven tokens-fragmento (so, co, dde, e) producidos por la pérdida de glifos del OCR original — la materialidad del corpus, cuantificada por la propia herramienta. Cada operación quedó registrada para su trazabilidad.

Esto responde directamente a la pregunta por la materialidad: las frecuencias que Voyant devuelve no son propiedades del texto literario sino del objeto digital que lo transporta. Sin esta curaduría, la nube de palabras habría incluido tokens como isbn, www o ficci — huellas del libro-objeto y de su digitalización, no de la prosa de los autores.

3. Inspección inicial sin filtros

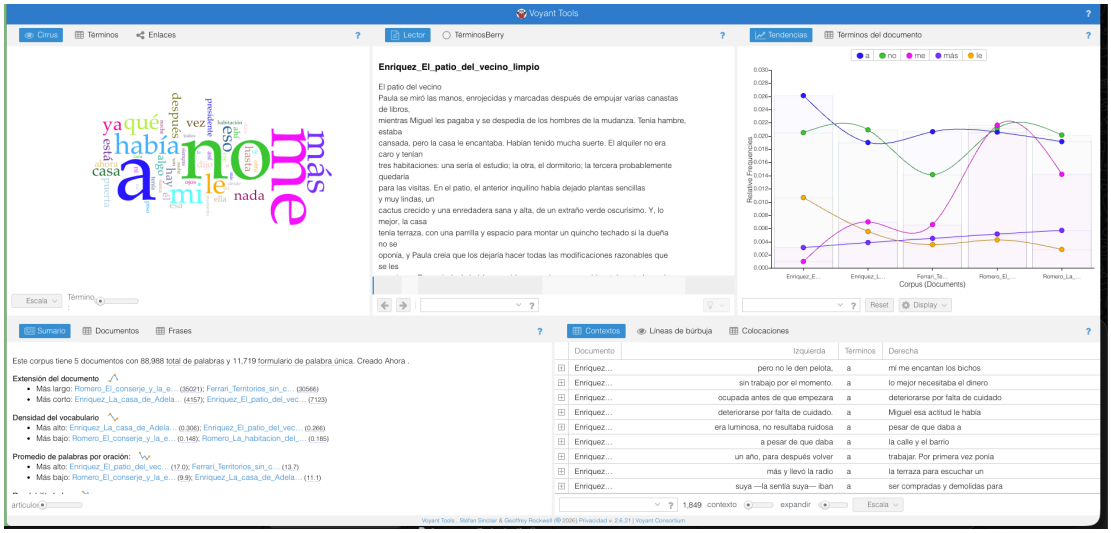


Figura 1
Vista general del corpus en Voyant Tools sin filtrado de palabras vacías (Cirrus y Sumario). Nota. Elaboración propia a partir de Voyant Tools (Sinclair & Rockwell, v. 2.6.21), mirror SADiLaR. Corpus de cinco documentos, 88.988 palabras.

La inspección sin filtros muestra el predominio esperable de palabras funcionales, con una excepción significativa: la negación no figura entre las formas dominantes del Cirrus crudo (conteo preliminar local: 1.652 ocurrencias), un dato que las stopwords borrarán pero sobre el que vuelvo en el punto 4. El Sumario aporta tres datos de estructura. Primero, la asimetría de la muestra: las dos obras de mayor extensión (El conserje, 35.021 tokens; Territorios, 30.566)

concentran casi tres cuartos del corpus, lo que obliga a trabajar con frecuencias relativas en toda comparación entre documentos. Segundo, la densidad léxica (0,306 en Adela contra 0,148 en El conserje) sigue el orden inverso de la extensión, como es esperable por la ley de rendimientos decrecientes del vocabulario, por lo que no debe leerse como indicador directo de riqueza estilística. Tercero, y más interesante: el promedio de palabras por oración distingue respiraciones sintácticas — El conserje y la eternidad tiene la oración más corta del corpus (9,9 palabras), casi la mitad que El patio del vecino (17,0), un dato de ritmo que la lectura cercana percibe pero no mide.

4. Lista de palabras vacías: qué se filtró y qué no

Se partió de la lista en español por defecto de Voyant y se la editó en dos direcciones, guardando las decisiones en el archivo stopwords_UmbralWeird_v2_completa.txt.

4.1. Palabras agregadas

- Verbos de marco dialogal (dijo, preguntó, respondió y variantes): marcan densidad de diálogo pero saturan el Cirrus sin aportar a la pregunta de investigación.
- Sustantivos y adverbios genéricos de relleno narrativo (cosa, vez, momento, manera, bien, aunque).
- Conjugaciones frecuentes de verbos soporte (hacer, tener, poder, saber, quedar) que la lista por defecto no cubre.
- Formas del voseo rioplatense (vos, tenés, sabés, querés, sos, mirá): las listas de stopwords estándar están construidas sobre un español peninsular o neutro y no contemplan la conjugación voseante, de modo que los diálogos de un corpus argentino quedan sin filtrar. Que hasta la lista de palabras vacías tenga un Norte es una versión mínima de la geopolítica del conocimiento discutida en la unidad.

4.2. Palabras deliberadamente no filtradas

- El léxico espacial-doméstico (casa, puerta, habitación, piso, pared, ventana, escalera, altillo, sótano, patio): es el objeto mismo de la hipótesis del umbral.
- Los indefinidos algo, nada, nadie, alguien, que la lista por defecto de Voyant elimina y que aquí se restituyeron quitándolos de la lista: en un corpus weird, la agencia indefinida (“algo la sostenía”) y la ausencia (“nadie”) no son ruido gramatical sino gramática del fenómeno.
- La deixis temporal (ahora, después, entonces, nunca, siempre) y el propio sustantivo tiempo, que la lista por defecto elimina: en un corpus donde la eternidad y la desarticulación del tiempo son tema, la densidad de estos marcadores es señal, no ruido. En la sesión final de Voyant, no obstante, tiempo y entonces quedaron filtradas por un residuo de la lista anterior en el editor de la herramienta; sus frecuencias se reportan por conteo local en el punto 5.
- Los adverbios espaciales dentro, encima y arriba, y el sustantivo trabajo, también removidos de la lista por defecto: la primera tríada integra la gramática espacial que es objeto de la hipótesis, y trabajo es léxico social central en Ferrari.
- Los nombres propios de personajes: siguiendo la pregunta de quién recibe un nombre en un texto, se conservaron — que Paula, Adela u Omarcito dominen sus documentos es un dato de régimen narrativo, no ruido.

Dos palabras se mantuvieron filtradas para el Cirrus pero se examinaron por separado mediante Tendencias y Contextos: no (su frecuencia aplastaría toda visualización, pero la hipótesis de la tesis vincula el Weird con formas de conocimiento negativo) y solo, que mezcla

de modo indistinguible el adverbio (solamente) con el adjetivo de soledad — tema central de El conserje y la eternidad. Esa ambigüedad que Voyant no puede resolver es otro ejemplo concreto del problema de la caja negra: la desambiguación queda a cargo del analista, en Contextos.

5. Cirrus y Tendencias: patrones y diálogo con las hipótesis

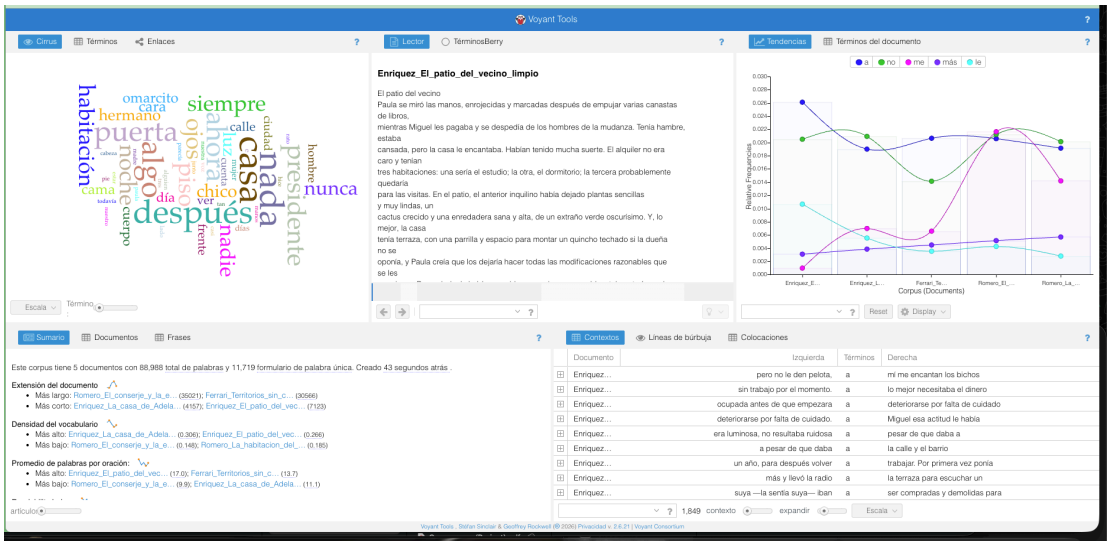


Figura 2
Cirrus del corpus depurado con la lista de palabras vacías personalizada. Nota. Elaboración propia a partir de Voyant Tools (Sinclair & Rockwell, v. 2.6.21). Se distinguen los tres clústeres analizados en el punto 5: léxico arquitectónico-perceptivo, indefinidos y deixis temporal.

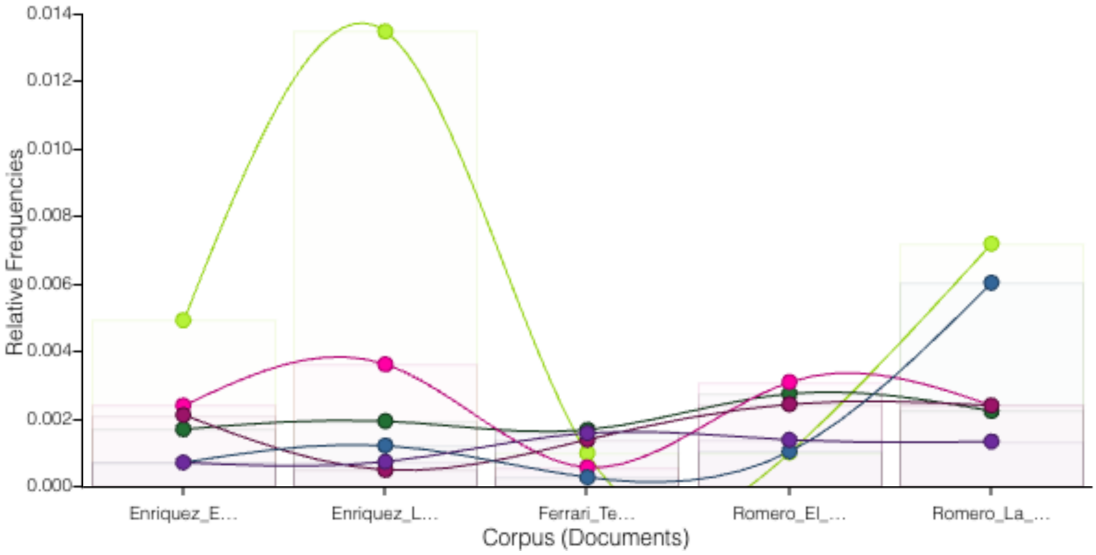


Figura 3
Frecuencias relativas de casa, puerta, habitación, nada, algo y nadie por documento (Tendencias). Nota. Elaboración propia a partir de Voyant Tools (Sinclair & Rockwell, v. 2.6.21). El pico de casa corresponde a La casa de Adela (0,0132); el ascenso final de habitación, a La habitación del presidente.

Todas las cifras provienen de las tablas de Términos de Voyant, salvo tiempo y entonces, verificadas solo en conteo local — ver la nota sobre la lista al final del punto 4. El conteo local en Python y el de Voyant difirieron en ±1 en dos términos (casa, habitación): la discrepancia mínima confirma que tokenizadores distintos cuentan distinto; ver punto 6. Tras la limpieza, el Cirrus queda dominado por tres clústeres que son, exactamente, las tres capas de la hipótesis. Primero, el arquitectónico-perceptivo: casa (206), puerta (168), piso (135), ojos (133), habitación (126), noche (124), luz (106). La conjetura de que la sensibilidad weird de este corpus se materializa en el espacio doméstico y en un régimen perceptivo alterado no solo dialoga con estos resultados: queda confirmada en su formulación más literal. El umbral no es aquí una metáfora importada por el analista; es la puerta, contada 168 veces.

Segundo patrón: cada texto tiene una firma espacial propia, visible en Tendencias y en la tabla de Términos del documento. El altillo pertenece exclusivamente a La habitación del presidente (26 ocurrencias, ninguna en el resto del corpus), donde también dominan presidente (140), hermano (65) y la constelación posesiva de la primera persona plural (nuestra, 41; nuestro, 35; nuestros, 14): la voz de la casa es la voz de una familia. En El conserje se concentran puerta (96), piso (101), edificio (39) y cocina (31) — el weird vertical del edificio —, junto al sótano y el pasillo. El patio (30) y la terraza (20) pertenecen a Enríquez. Y en Ferrari el espacio dominante no es doméstico sino urbano-territorial: ciudad concentra allí 59 de sus 82 ocurrencias. La distinción que esto sugiere — un weird doméstico (Romero, Enríquez) frente a un weird territorial (Ferrari) — es explotable por la tesis y coherente con el propio título del libro de Ferrari.

Un patrón no previsto emergió de la misma tabla: en El conserje y la eternidad, los términos de mayor frecuencia relativa incluyen fechas y meses — 2001 (39), diciembre (38), 1982 (35), 1955 (33), junio (32), abril (31). La arquitectura temporal de la novela, sus tres épocas, no es solo un dato de estructura externa: es léxico de superficie, visible para la lectura distante sin abrir el libro. A esto se suma la marca enunciativa: escribo (37), escribir (29), miré, vi, salí, dejé — el pretérito de primera persona como régimen dominante, ausente en el resto del corpus. La lectura distante no solo localiza espacios: distingue voces.

Tercer patrón, el más inesperado: el clúster de indefinidos restituidos — nada (194), algo (173), nadie (120), alguien (69) — suma 556 ocurrencias, un volumen comparable al del léxico doméstico. Y la deixis temporal conservada forma el tercer clúster visible: después (182), ahora (156), siempre (122), nunca (109), y — según el conteo local — entonces (~136) y tiempo (~103). La lectura distante vuelve visible algo que la lectura cercana registra caso por caso pero no puede cuantificar: en este corpus la agencia tiende a lo innominado y la experiencia está saturada de marcas temporales.

Finalmente, un hallazgo por ausencia: la palabra umbral aparece apenas tres veces en todo el corpus (solo en Romero). La categoría central de la tesis es prácticamente inexistente como término en los textos que analiza. Lejos de refutar la hipótesis, este dato la precisa: el umbral es un instrumento abstracto del análisis, no un léxico de los autores — exactamente el precio del conocimiento teórico que Moretti (2000) describe citando a Weber: los conceptos son pobres frente a la riqueza infinita de lo empírico, y por eso sirven para dominarla.

6. Ventaja heurística de la visualización frente al Sumario

El Sumario informa magnitudes (tokens, tipos, densidad léxica) que describen el corpus como objeto, pero no orientan preguntas. Cirrus y Tendencias, en cambio, funcionaron como la brújula que describe la unidad: el Cirrus hizo visible en segundos la co-presencia del léxico arquitectónico y el perceptivo — que en una tabla de frecuencias son filas separadas —, y Tendencias convirtió la comparación entre documentos en un gesto perceptivo inmediato,

revelando las firmas espaciales de cada texto. La visualización no agregó datos: agregó relaciones entre datos, que es donde empiezan las hipótesis.

Cabe una advertencia metodológica en la línea de la "caja negra" discutida en la unidad: los conteos preliminares realizados localmente en Python y los de Voyant difieren levemente porque cada entorno tokeniza distinto (tratamiento de apóstrofos, guiones y mayúsculas). Esa diferencia, lejos de ser un defecto, es la demostración empírica de que la tokenización es una decisión interpretativa automatizada: dos máquinas que "leen" el mismo archivo no cuentan las mismas palabras. Documentar ambos conteos es la forma mínima de no perder el control sobre esa decisión.

7. Uso de inteligencia artificial

Para la fase de curaduría y análisis preliminar utilicé Claude (Anthropic, 2026) como asistente de procesamiento bajo instrucciones específicas y verificación humana por etapa. Las directivas dadas al modelo fueron: (1) diagnosticar encoding y calidad de OCR de los cinco archivos fuente — de donde surgieron la codificación Mac Roman de *Territorios* y la pérdida de ligaduras "fi" en la capa de texto del PDF de *El patio del vecino*; (2) normalizar a UTF-8 y recortar los paratextos editoriales y web según límites que validé caso por caso (biografías de solapa, colofones, prólogo ajeno, citas de prensa, catálogo, encabezados web); (3) aplicar reparaciones regladas y cuantificadas: reunión de 773 palabras cortadas por guion blando y reparación mediante expresión regular de 143 truncamientos de la terminación "-ción"; (4) contrastar empíricamente la lista de palabras vacías contra las frecuencias reales del corpus, para fundamentar tanto las altas (voseo, verbos dialogales) como las bajas (indefinidos, deixis temporal); y (5) computar en Python un conteo preliminar de frecuencias, utilizado como conjunto de hipótesis a verificar luego en Voyant, junto con el esqueleto de este reporte. Cada operación quedó registrada en la sesión de trabajo y es reproducible. La selección del corpus y de la muestra, las decisiones de curaduría — incluido el reemplazo de fuente de *La casa de Adela* —, la carga y configuración en Voyant, las capturas, la verificación de cifras contra las tablas de la herramienta y la redacción final del reporte son propias.

Referencias

Anthropic. (2026). Claude (Fable 5) [Modelo de lenguaje de gran escala].

https://claude.ai [Fecha de acceso: 9 de septiembre de 2026].

Moretti, F. (2000). Conjeturas sobre la literatura mundial. New Left Review, 3, 59-71.

Sinclair, S., & Rockwell, G. (2026). Voyant Tools (versión 2.6.21) [Software].

https://voyant-tools.org/